

## ЗАНЯТИЕ 2. РЕГРЕССИЯ

ИТОГ

### Градиентный спуск

При обучении модели у нас есть функция потерь, которую мы должны минимизировать. ( $Q(\bar{w}) \rightarrow \min$ ).

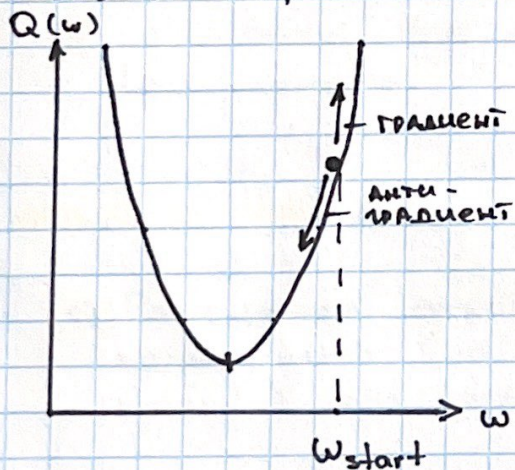
Есть 2 подхода:

$$\left. \begin{array}{l} \text{1. аналитический: } Q'(w_0) = 0 \\ Q'(w_1) = 0 \\ Q''(w_n) = 0 \end{array} \right\}$$

Проблема: не каждое уравнение можно решить; не всегда можем найти точное решение

2. численный: градиентный спуск

Допустим, мы хотим минимизировать MSE:



Наша цель - научить компьютер проходить численно в точку мин-ма

Шаг 1: встаём в произвольную точку на функции ( $w_{start}$ ) и в этой точке посчитаем градиент

Градиент - это вектор, который указывает направление наискорейшего роста функции.

В нашем случае нужен антиградиент (ищем минимум). Получаем формулу:

$$w_{new} := w_{old} - \frac{\nabla Q(w_{old})}{\text{градиент}}$$



Пояснение: мы встаём в точку, считаем градиент и сдвигаемся в сторону антиградиента, т.е. из веса вычитаем значение антиградиента и попадаем в новую точку

Другая запись:

$$w^{(k+1)} = w^{(k)} - \nabla Q(w^{(k)})$$

Проблема: какой шаг делать?

→ нужно добавить параметр  $\eta$ , который будет задавать шаг градиентного спуска (гиперпараметр метода, то число, которое мы задаём сами)

$$w^{(k+1)} = w^{(k)} - \eta \nabla Q(w^{(k)})$$

На практике  $\eta [0,001, 0,01]$  - нормальный градиентный шаг (learning rate)

Стахастический градиентный спуск, SGD

При большом объёме данных обычный градиентный будет слишком долго работать.

Предлагается на 1 итерацию брать 1 случайный объект:

$$w^{(k+1)} := w^{(k)} - \eta \nabla_{i_k} Q(w^{(k)})$$



## Нормализация / масштабирование / стандартизация признаков

Допустим у нас есть признаки:

$X_1$  - возраст  $\sim$  десятки

$X_2$  - з/п  $\sim$  тысячи

$X_3$  - женат / не женат  $\sim$  0/1

Так как признаки разных масштабов, желательно приводить их к одному масштабу. Есть разные способы масштабирования, но самый простой:

$$\frac{x - \min}{\max - \min} \in [0; 1]$$

## Методы борьбы с переобучением: регуляризация

Если в выборке есть линейно-зависимые признаки, то задача оптимизации  $Q(w) \rightarrow \min$  имеет бесконечное число решений.

Большие значения параметров (весов) модели  $w$  - признак переобучения.

Решение проблемы - регуляризация.

Будем минимизировать регуляризованный функционал ошибки:

$$Q_{\alpha}(w) = Q(w) + \alpha \cdot R(w) \rightarrow \min_w, \text{ где}$$

$R(w)$  - регуляризатор

Регуляризация штрафует слишком большие веса.



## Наиболее используемые регуляризаторы:

- $L_2$  - регуляризатор:  $R(w) = \|w\|_2 = \sum_{i=1}^d w_i^2$
- $L_1$  - регуляризатор:  $R(w) = \|w\|_1 = \sum_{i=1}^d |w_i|$

Пример регуляризованного функционала:

$$Q(a(w), X) = \frac{1}{L} \sum_{i=1}^L ((w, x_i) - y_i)^2 + \alpha \sum_{i=1}^d w_i^2,$$

где  $\alpha$  - коэффициент регуляризации